

Privacy by Design: Entwicklung und Bewertung eines Offline-Sprachassistenten als Alternative zu Cloud-basierten Systemen

Moritz Rühm

Bachelor-Thesis

zur Erlangung des akademischen Grades Bachelor of Science (B.Sc.)

Studiengang Unternehmens- und Wirtschaftsinformatik

Fakultät für Informatik

Technische Hochschule Mannheim

31.05.2026

Betreuer

Prof. Kai Eckert, Technische Hochschule Mannheim

Prof. Oliver Hummel, Technische Hochschule Mannheim

Rühm, Moritz:

Privacy by Design: Entwicklung und Bewertung eines Offline-Sprachassistenten als Alternative zu Cloud-basierten Systemen / Moritz Rühm. –

Bachelor-Thesis, Mannheim: Technische Hochschule Mannheim, 2026. 30 Seiten.

Rühm, Moritz:

Privacy by Design: Development and evaluation of an offline voice assistant as an alternative to cloud-based systems / Moritz Rühm. –

Bachelor Thesis, Mannheim: University of Applied Sciences Mannheim, 2026. 30 pages.

Um die Lesbarkeit zu vereinfachen, wird auf die zusätzliche Formulierung der weiblichen Form bei Personenbezeichnungen verzichtet. Ich weise deshalb darauf hin, dass die Verwendung der männlichen Form explizit als geschlechtsunabhängig verstanden werden soll.

Erklärung

Hiermit erkläre ich, dass ich die vorliegende Arbeit selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe. Der Einsatz künstlicher Intelligenz erfolgte ausschließlich unterstützend, insbesondere zur Literaturrecherche sowie zur Überprüfung von Rechtschreibung und sprachlicher Verständlichkeit.


Mannheim, 31.05.2026

A handwritten signature in black ink, consisting of a large, stylized capital 'M' followed by a capital 'R' and a capital 'H'.

Moritz Rühm

Ich bin damit einverstanden, dass meine Arbeit veröffentlicht wird, d. h. dass die Arbeit elektronisch gespeichert, in andere Formate konvertiert, auf den Servern der Technischen Hochschule Mannheim öffentlich zugänglich gemacht und über das Internet verbreitet werden darf.

Dieses Werk ist lizenziert unter einer [Creative Commons „Namensnennung – Weitergabe unter gleichen Bedingungen 4.0 International“](#) Lizenz.



Abstrakt

Privacy by Design: Entwicklung und Bewertung eines Offline-Sprachassistenten als Alternative zu Cloud-basierten Systemen

Jemand musste Josef K. verleumdet haben, denn ohne dass er etwas Böses getan hätte, wurde er eines Morgens verhaftet. Wie ein Hund! sagte er, es war, als sollte die Scham ihn überleben. Als Gregor Samsa eines Morgens aus unruhigen Träumen erwachte, fand er sich in seinem Bett zu einem ungeheueren Ungeziefer verwandelt. Und es war ihnen wie eine Bestätigung ihrer neuen Träume und guten Absichten, als am Ziele ihrer Fahrt die Tochter als erste sich erhob und ihren jungen Körper dehnte. Es ist ein eigentümlicher Apparat, sagte der Offizier zu dem Forschungsreisenden und überblickte mit einem gewissermaßen bewundernden Blick den ihm doch wohl bekannten Apparat. Sie hätten noch ins Boot springen können, aber der Reisende hob ein schweres, geknotetes Tau vom Boden, drohte ihnen damit und hielt sie dadurch von dem Sprunge ab. In den letzten Jahrzehnten ist das Interesse an Künstlern sehr zurückgegangen. Aber sie überwandten sich, umdrängten den Käfig und wollten sich gar nicht fortrühren.

Abstract

Privacy by Design: Development and evaluation of an offline voice assistant as an alternative to cloud-based systems

The European languages are members of the same family. Their separate existence is a myth. For science, music, sport, etc, Europe uses the same vocabulary. The languages only differ in their grammar, their pronunciation and their most common words. Everyone realizes why a new common language would be desirable: one could refuse to pay expensive translators. To achieve this, it would be necessary to have uniform grammar, pronunciation and more common words. If several languages coalesce, the grammar of the resulting language is more simple and regular than that of the individual languages. The new common language will be more simple and regular than the existing European languages. It will be as simple as Occidental; in fact, it will be Occidental. To an English person, it will seem like simplified English, as a skeptical Cambridge friend of mine told me what Occidental is.

Inhaltsverzeichnis

Abkürzungsverzeichnis	vii
Abbildungsverzeichnis	viii
Tabellenverzeichnis	ix
Quellcodeverzeichnis	x
1 Einleitung	1
1.1 Problemstellung	1
1.2 Motivation	1
1.3 Ziel der Arbeit	1
2 Theoretische Grundlagen	2
2.1 Sprachassistenzsysteme	2
2.2 Wake-Word-Erkennung	3
2.3 Speech-To-Text	5
2.4 Large Language Models	7
2.5 Text-To-Speech	9
2.6 Aktueller Stand der Technologie?	11
3 Methodik	12
3.1 Forschungsansatz: Design Science Research Methodology	12
3.2 Evaluationskonzept	13
4 Prototypische Implementierung	15
4.1 Anforderungsanalyse	15
4.2 Auswahl der Entwicklungsplattform und Komponenten	15
4.3 Umsetzung	15
4.4 Demonstration	15
5 Evaluation	16
5.1 Versuche auf verschiedener Hardware	16
5.1.1 Raspberry Pi	16

5.1.2	Macbook Air M4	16
5.1.3	Beelink GT9 Pro	16
5.2	Vergleich mit Cloud-basierten Lösungen und DIY-Architekturen	16
5.2.1	Alexa	16
5.2.2	Siri	16
5.2.3	Homeassistant Voice Assistant	16
5.3	Use-Cases	16
5.3.1	Smart-Home Steuerung	16
5.3.2	Pflege	16
5.3.3	Hausaufgaben Helfer	16
6	Fazit und Ausblick	17
6.1	Ergebnisinterpretation	17
6.2	Beitrag der Arbeit	17
6.3	Limitationen der Studie	17
6.4	Forschungsausblick	17
	Literatur	xi
	A Anhang A	xii
	B Anhang B	xiii

Abkürzungsverzeichnis

ASR	Automatic Speech Recognition
CTC	Connectionist Temporal Classification
DNN	Deep Neural Networks
DSR	Design-Science-Research
DSRM	Design-Science-Research-Methodology
HMM	Hidden-Markov-Modelle
LLM	Large Language Model
MFCC	Mel-Frequency Cepstral Coefficients
MOS	Mean Opinion Score
NLP	Natural Language Processing
RNN	rekurrentes neuronales Netz
STT	Speech-to-Text
TTS	Text-to-Speech
WER	Word Error Rate

Abbildungsverzeichnis

Tabellenverzeichnis

Quellcodeverzeichnis

Kapitel 1

Einleitung

1.1 Problemstellung

Test1

1.2 Motivation

Test2

1.3 Ziel der Arbeit

Test3

Kapitel 2

Theoretische Grundlagen

Moderne Sprachassistenzsysteme basieren auf dem Zusammenspiel zahlreicher komplexer Bausteine, die in ihrer Gesamtheit eine natürliche und effiziente Interaktion zwischen Mensch und Maschine ermöglichen. Dabei kommen insbesondere Verfahren aus den Bereichen künstliche Intelligenz, maschinelles Lernen und Sprachverarbeitung zum Einsatz. Für ein fundiertes Verständnis der in den folgenden Kapiteln behandelten Konzepte und Implementierungen müssen zunächst grundlegende theoretische Ansätze dieser einzelnen Elemente erläutert werden.

2.1 Sprachassistenzsysteme

Sprachassistenzsysteme, auch Voice Assistants genannt, sind softwarebasierte Systeme, die gesprochene Sprache verarbeiten, interpretieren und darauf reagieren können. Bekannte Vertreter sind beispielsweise Siri, Alexa oder der Google Assistant. Diese Systeme ermöglichen es Nutzern über natürliche Sprachbefehle mit digitalen Geräten zu interagieren und verschiedene Aufgaben, wie das Abfragen von Informationen, die Steuerung von Smart-Home-Geräten oder der Terminplanung, ohne jegliche manuelle Eingaben durchzuführen.

Die Entwicklung moderner Sprachassistenzsysteme wurde insbesondere durch Fortschritte im Bereich der künstlichen Intelligenz sowie der digitalen Sprachverarbeitung ermöglicht. Während frühe Systeme häufig nur auf fest definierte Befehle reagieren konnten, sind aktuelle Sprachassistenten deutlich flexibler und können unterschiedliche Formulierungen einer Anfrage verarbeiten. Dadurch wirkt die Kommunikation natürlicher und benutzerfreundlicher.

Der grundlegende Ablauf eines Sprachassistenzsystems besteht aus mehreren Verarbeitungsschritten. Zunächst wird die Sprache des Nutzers mithilfe eines Mikrofons aufgenommen und in ein digitales Audiosignal umgewandelt. Anschließend erfolgt die automatische Spracherkennung Automatic Speech Recognition (ASR), bei der die gesprochenen Wörter analysiert und in Text umgewandelt werden. Für diesen Schritt kommen moderne Verfahren des maschinellen Lernens und neuronale Netze zum Einsatz, die mit großen

Mengen an Sprachdaten trainiert werden. Ziel der Spracherkennung ist es, die gesprochenen Inhalte möglichst präzise zu erfassen.

Nach der Spracherkennung wird die Eingabe durch Verfahren der natürlichen Sprachverarbeitung Natural Language Processing (NLP) analysiert. Dabei versucht das System, die Bedeutung der Aussage sowie die Absicht des Nutzers zu erkennen. Neben einzelnen Wörtern werden hierbei auch Satzstrukturen und sprachliche Zusammenhänge berücksichtigt. Auf Grundlage dieser Analyse entscheidet das System, welche Aktion ausgeführt oder welche Antwort erzeugt werden soll.

Die Ausgabe des Systems erfolgt anschließend über eine Sprachsynthese Text-to-Speech (TTS). Dabei wird der generierte Text wieder in gesprochene Sprache umgewandelt. Moderne Sprachsynthesesysteme erzeugen zunehmend natürliche und flüssig klingende Stimmen, wodurch die Interaktion mit Sprachassistenzsystemen für Nutzer angenehmer wirkt. Sprachassistenzsysteme finden heute in zahlreichen Bereichen Anwendung. Sie werden beispielsweise in Smartphones, Lautsprechersystemen, Fahrzeugen oder Smart-Home-Geräten eingesetzt. Nutzer können damit Informationen abrufen, Erinnerungen erstellen oder verschiedene Funktionen sprachgesteuert bedienen. Durch die intuitive Sprachsteuerung ermöglichen Sprachassistenzsysteme eine vereinfachte Interaktion mit digitalen Technologien und tragen zu einer höheren Benutzerfreundlichkeit bei.

Insgesamt stellen Sprachassistenzsysteme einen wichtigen Bestandteil moderner Mensch-Maschine-Interaktion dar. Durch die Kombination aus Sprachverarbeitung, Spracherkennung und Sprachsynthese ermöglichen sie eine natürliche und intuitive Kommunikation zwischen Nutzern und technischen Systemen.

Nochmal drüber gehen

2.2 Wake-Word-Erkennung

Die Wake-Word-Erkennung bildet bei sprachbasierten Assistenzsystemen die erste technische und zugleich interaktive Stufe der Sprachverarbeitung. Ein Wake-Word, beispielsweise „Alexa“, „Hey Siri“ oder „Ok Google“, dient als Aktivierungssignal, mit dem ein System erkennt, dass eine nachfolgende Äußerung an den digitalen Assistenten gerichtet ist. Erst nach der Erkennung dieses Schlüsselwortes beginnt das System damit, die anschließende Spracheingabe als eigentlichen Nutzerbefehl aufzunehmen und weiterzuverarbeiten. Damit übernimmt die Wake-Word-Erkennung eine Filterfunktion und trennt alltägliche Hintergrundsprache von Befehls- und Fragesätzen, welche an das System gerichtet sind.

Aus architektonischer Sicht wird die Wake-Word-Erkennung typischerweise vor der eigentlichen Speech-To-Text Verarbeitung platziert. Während automatische Spracherkennungssysteme gesprochene Sprache in Text umwandeln und dabei akustische Modellie-

rung, Sprachmodellierung und Dekodierung einsetzen, ist die Wake-Word-Erkennung stärker auf die robuste Erkennung eines sehr kleinen, fest definierten Vokabulars spezialisiert. Sie muss daher nicht jede gesprochene Äußerung vollständig verstehen, sondern lediglich entscheiden, ob ein bestimmtes Aktivierungswort im Audiosignal enthalten ist. Nach erfolgreicher Aktivierung wird die eigentliche Nutzeranfrage aufgenommen, häufig bis eine kurze Sprechpause als Ende der Eingabe erkannt wird.

Technisch betrachtet muss ein Wake-Word-System dauerhaft oder nahezu dauerhaft aktiv sein, da es das Aktivierungssignal jederzeit erkennen muss. Daraus ergibt sich eine besondere Anforderung an Effizienz und Ressourcenschonung. Im Gegensatz zur vollständigen automatischen Spracherkennung darf die Wake-Word-Erkennung nur geringe Rechenleistung und wenig Energie benötigen, insbesondere wenn sie auf leistungsarmen Geräten wie Smart Speakern oder Single-board Computern betrieben wird. In vielen Systemen wird deshalb ein leichtgewichtiges lokales Modell eingesetzt, das kontinuierlich kurze Audiobereiche analysiert. Erst wenn dieses Modell eine ausreichende Wahrscheinlichkeit für das Wake-Word erkennt, werden rechenintensivere Verarbeitungsschritte aktiviert.

Ein zentrales Qualitätskriterium ist dabei die Balance zwischen Fehlaktivierungen und verpassten Aktivierungen. Eine Fehlaktivierung liegt vor, wenn das System irrtümlich annimmt, das Wake-Word gehört zu haben, obwohl der Nutzer den Assistenten nicht ansprechen wollte. Dies kann zum Beispiel bei ähnlich klingenden Wörtern oder Namen auftreten. Eine verpasste Aktivierung liegt hingegen vor, wenn das Wake-Word tatsächlich gesprochen wurde, das System es aber nicht erkennt. Beide Fehlerarten beeinträchtigen die Nutzererfahrung: Fehlaktivierungen können als störend oder sogar als Datenschutzproblem wahrgenommen werden, während verpasste Aktivierungen zu Frustration führen, weil Nutzer ihre Anfrage wiederholen müssen.

Neben der Bedienbarkeit spielt auch der Datenschutz eine wichtige Rolle. Da Wake-Word-Erkennung voraussetzt, dass das Gerät kontinuierlich auf Audiosignale achtet, entsteht bei Nutzern häufig der Eindruck eines permanent mithörenden Systems. Anbieter betonen zwar, dass Aufzeichnungen erst nach dem Wake-Word erfolgen, dennoch bleibt die technische Voraussetzung bestehen, dass das Gerät fortlaufend Audiodaten lokal analysiert. Fehlfunktionen, Fehlaktivierungen oder Angriffe können dazu führen, dass Spracheingaben unbeabsichtigt verarbeitet werden.

Test

Für die Gestaltung moderner Sprachassistenzsysteme ist die Wake-Word-Erkennung daher mehr als nur ein technisches Detail. Sie beeinflusst, wie natürlich, zuverlässig und vertrauenswürdig ein System wahrgenommen wird. Eine gute Wake-Word-Erkennung muss robust gegenüber Hintergrundgeräuschen, unterschiedlichen Stimmen, Akzenten und ähnlichen Lautfolgen sein. Gleichzeitig sollte sie möglichst wenige Daten außerhalb des Geräts verarbeiten, um Datenschutzrisiken zu reduzieren. Perspektivisch könnten in Zukunft

Alternativen oder Ergänzungen zum klassischen Wake-Word, wie etwa kontextabhängige Aktivierung, dedizierte Gesprächsmodi oder lernende Systeme, die aus vorherigen Interaktionen ableiten, wann eine Äußerung wahrscheinlich an den Assistenten gerichtet ist, an Bedeutung gewinnen.

Zusammenfassend ist die Wake-Word-Erkennung die Aktivierungsschicht eines Voice Assistants. Sie entscheidet, wann aus passivem Zuhören eine aktive Sprachinteraktion wird. Ihre Aufgabe besteht darin, ein festgelegtes Schlüsselwort zuverlässig, ressourcenschonend und möglichst datenschutzfreundlich zu erkennen.

2.3 Speech-To-Text

Die automatische Spracherkennung, häufig als Speech-to-Text (STT) oder Automatic ASR bezeichnet, stellt eine zentrale Schlüsseltechnologie innerhalb moderner Sprachassistenzsysteme dar. Ihr Ziel besteht darin, gesprochene Sprache in schriftlichen Text zu überführen, der anschließend von weiteren Systemkomponenten verarbeitet werden kann. Ohne eine zuverlässige und präzise Spracherkennung wäre eine natürliche sprachbasierte Interaktion zwischen Mensch und Maschine nicht möglich. Systeme wie Siri, Alexa oder Google Assistant greifen daher maßgeblich auf leistungsfähige Speech-to-Text-Verfahren zurück.

Die grundlegende Herausforderung der automatischen Spracherkennung liegt in der Transformation eines kontinuierlichen, hochvariablen Audiosignals in eine diskrete Folge von Wörtern. Sprache ist dabei durch eine Vielzahl von Einflussfaktoren geprägt, darunter unterschiedliche Sprecher, Dialekte, Sprechgeschwindigkeiten, Intonationen sowie Umgebungsgeräusche. Ziel eines ASR-Systems ist es, trotz dieser Variabilität eine möglichst korrekte Transkription zu erzeugen.

Der Prozess der automatischen Spracherkennung lässt sich in mehrere aufeinanderfolgende Verarbeitungsschritte gliedern. Zunächst erfolgt die Aufnahme des Sprachsignals über ein Mikrofon. Dieses Rohsignal wird anschließend in einem Vorverarbeitungsschritt aufbereitet, wobei Störgeräusche reduziert und das Signal normalisiert werden. Darauf folgt die Extraktion relevanter Merkmale, die die charakteristischen Eigenschaften der Sprache kompakt repräsentieren. Häufig werden hierfür spektrale Merkmale wie Mel-Frequency Cepstral Coefficients (MFCC) oder Log-Mel-Spektrogramme verwendet.

Im nächsten Schritt erfolgt die eigentliche akustische Modellierung. Hierbei wird eine Zuordnung zwischen den extrahierten Merkmalen und sprachlichen Einheiten, wie Phonemen oder direkt Wörtern, hergestellt. Klassische Ansätze basierten auf Hidden-Markov-Modelle (HMM), die mit statistischen Verfahren kombiniert wurden. In modernen Systemen werden diese zunehmend durch neuronale Netze ersetzt, insbesondere durch tie-

fe neuronale Netze (Deep Neural Networks (DNN)), rekurrentes neuronales Netz (RNN) oder transformerbasierte Architekturen. Diese Modelle sind in der Lage, komplexe zeitliche Abhängigkeiten im Sprachsignal zu erfassen und dadurch eine deutlich höhere Erkennungsgenauigkeit zu erreichen.

Neben dem akustischen Modell spielt das Sprachmodell eine entscheidende Rolle. Dieses modelliert die Wahrscheinlichkeit von Wortfolgen und hilft dabei, aus mehreren möglichen Transkriptionsvarianten die plausibelste auszuwählen. Beispielsweise kann ein Sprachmodell entscheiden, ob in einem bestimmten Kontext eher das Wort „Bank“ im Sinne eines Finanzinstituts oder im Sinne einer Sitzgelegenheit gemeint ist. Moderne Sprachmodelle basieren häufig auf neuronalen Netzen und berücksichtigen große Textkorpora, um sprachliche Zusammenhänge zu lernen.

Ein weiterer wichtiger Bestandteil ist der Decoder, der die Informationen aus dem akustischen Modell und dem Sprachmodell kombiniert, um die wahrscheinlichste Wortsequenz zu bestimmen. Dieser Prozess wird häufig als Decoding bezeichnet und stellt einen zentralen Schritt in der Gesamtsystemarchitektur dar.

In den letzten Jahren hat sich ein Paradigmenwechsel hin zu sogenannten End-to-End-Modellen vollzogen. Diese Ansätze verzichten auf eine explizite Trennung zwischen akustischem und sprachlichem Modell und lernen stattdessen direkt die Abbildung vom Audiosignal auf die entsprechende Textsequenz. Beispiele hierfür sind Modelle basierend auf Connectionist Temporal Classification (CTC), Attention-Mechanismen oder Transformer-Architekturen. Diese Modelle vereinfachen die Systemarchitektur und ermöglichen häufig eine bessere Anpassung an spezifische Anwendungsfälle.

Ein zentrales Qualitätsmaß für Speech-to-Text-Systeme ist die sogenannte Word Error Rate (WER). Sie gibt an, wie viele Fehler bei der Transkription im Verhältnis zur Gesamtanzahl der Wörter auftreten. Dabei werden Einfügungen, Löschungen und Substitutionen berücksichtigt. Eine niedrige WER ist ein Indikator für eine hohe Erkennungsgenauigkeit und somit für die Leistungsfähigkeit des Systems.

Trotz erheblicher Fortschritte stehen Speech-to-Text-Systeme weiterhin vor verschiedenen Herausforderungen. Dazu zählen insbesondere die Robustheit gegenüber Hintergrundgeräuschen, die Verarbeitung von Dialekten und Akzenten sowie das Verständnis von spontaner, unstrukturierter Sprache. Auch Mehrsprachigkeit stellt eine Herausforderung dar, insbesondere wenn innerhalb einer Äußerung zwischen verschiedenen Sprachen gewechselt wird (Code-Switching).

Ein weiterer wichtiger Aspekt ist die Frage der Verarbeitungslokation. Während viele Systeme traditionell cloudbasiert arbeiten und Audiodaten zur Verarbeitung an entfernte Server senden, gewinnen On-Device-Lösungen zunehmend an Bedeutung. Diese ermöglichen eine schnellere Reaktion, reduzieren die Abhängigkeit von Internetverbindungen und

tragen zur Verbesserung des Datenschutzes bei. Allerdings sind sie durch begrenzte Rechenressourcen eingeschränkt, was eine effiziente Modelloptimierung erforderlich macht. Zusammenfassend lässt sich festhalten, dass Speech-to-Text-Systeme eine fundamentale Grundlage für die Funktionsfähigkeit moderner Sprachassistenzsysteme darstellen. Sie ermöglichen die Umwandlung gesprochener Sprache in maschinenverarbeitbaren Text und bilden damit die Schnittstelle zwischen menschlicher Kommunikation und automatisierter Verarbeitung. Durch kontinuierliche Fortschritte im Bereich der künstlichen Intelligenz und des maschinellen Lernens ist in Zukunft mit weiteren Verbesserungen hinsichtlich Genauigkeit, Robustheit und Effizienz zu rechnen, wodurch die Bedeutung dieser Technologie weiter zunehmen wird.

2.4 Large Language Models

Large Language Models (LLMs) stellen eine zentrale technologische Grundlage moderner sprachverarbeitender Systeme dar und haben in den letzten Jahren maßgeblich zur Weiterentwicklung von Sprachassistenzsystemen beigetragen. Es handelt sich dabei um große, auf neuronalen Netzen basierende Modelle, die darauf trainiert sind, natürliche Sprache zu verstehen und zu generieren. Bekannte Vertreter solcher Modelle sind beispielsweise GPT-4 oder BERT, die in zahlreichen Anwendungen der natürlichen Sprachverarbeitung eingesetzt werden.

Der Begriff „large“ bezieht sich sowohl auf die Größe der Modelle als auch auf die Menge der Trainingsdaten. LLMs verfügen typischerweise über Milliarden bis hin zu Hunderten Milliarden von Parametern und werden auf umfangreichen Textkorpora trainiert, die aus Büchern, Webseiten und anderen Textquellen bestehen. Ziel dieses Trainings ist es, statistische Muster und Zusammenhänge in der Sprache zu erlernen, sodass das Modell in der Lage ist, kontextabhängige und kohärente Texte zu erzeugen.

Die Funktionsweise von LLMs basiert in der Regel auf der sogenannten Transformer-Architektur, die erstmals im Rahmen des wissenschaftlichen Beitrags „Attention Is All You Need“ vorgestellt wurde. Ein zentrales Element dieser Architektur ist der Attention-Mechanismus, der es dem Modell ermöglicht, relevante Teile eines Eingabetextes zu gewichten und somit Kontextinformationen effektiv zu berücksichtigen. Dadurch sind LLMs in der Lage, auch komplexe Abhängigkeiten innerhalb von Texten zu erfassen, die über einzelne Wörter oder Satzstrukturen hinausgehen.

Das Training eines Large Language Models erfolgt üblicherweise in zwei Phasen. In der ersten Phase, dem sogenannten Pretraining, wird das Modell auf großen, meist unannotierten Textdatensätzen trainiert. Dabei lernt es, das nächste Wort in einer Sequenz vorherzusagen oder fehlende Wörter zu ergänzen. Dieser Prozess ermöglicht es dem Modell, ein

grundlegendes Sprachverständnis zu entwickeln. In einer zweiten Phase, dem Fine-Tuning, wird das Modell auf spezifische Aufgaben oder Anwendungsfälle angepasst, häufig unter Verwendung annotierter Datensätze. Hierdurch kann das Modell gezielt für bestimmte Anwendungen optimiert werden, etwa für Dialogsysteme oder Textklassifikation.

Ein wesentliches Merkmal von LLMs ist ihre Fähigkeit zur Generierung natürlicher Sprache. Sie können auf Basis eines gegebenen Kontexts vollständige Sätze, Absätze oder sogar umfangreiche Texte erzeugen. Darüber hinaus sind sie in der Lage, verschiedene sprachbezogene Aufgaben zu lösen, darunter Textzusammenfassungen, Übersetzungen, Frage-Antwort-Systeme oder Dialogführung. Diese Vielseitigkeit macht sie zu einem zentralen Bestandteil moderner Sprachassistenzsysteme.

Im Kontext von Sprachassistenzsystemen übernehmen Large Language Models insbesondere Aufgaben im Bereich des Sprachverstehens und der Antwortgenerierung. Während klassische Systeme häufig auf regelbasierten Ansätzen oder vordefinierten Dialogstrukturen basierten, ermöglichen LLMs eine deutlich flexiblere und kontextsensitivere Interaktion. Nutzeranfragen können freier formuliert werden, und das System ist in der Lage, auch komplexe oder mehrdeutige Eingaben zu interpretieren und angemessen darauf zu reagieren.

Trotz ihrer Leistungsfähigkeit sind Large Language Models mit verschiedenen Herausforderungen verbunden. Eine zentrale Problematik besteht im hohen Rechen- und Speicherbedarf, sowohl während des Trainings als auch bei der Anwendung. Dies führt häufig dazu, dass LLMs in cloudbasierten Infrastrukturen betrieben werden, was wiederum Fragen hinsichtlich Datenschutz und Datenübertragung aufwirft. Zudem besteht die Gefahr, dass Modelle fehlerhafte oder ungenaue Informationen generieren, da sie auf statistischen Mustern basieren und kein echtes „Verständnis“ im menschlichen Sinne besitzen.

Ein weiterer kritischer Aspekt ist die mögliche Verzerrung (Bias) in den Trainingsdaten, die sich auf die Ausgaben des Modells auswirken kann. Da LLMs aus großen Mengen realer Textdaten lernen, können sie bestehende gesellschaftliche Vorurteile oder stereotype Darstellungen reproduzieren. Die Identifikation und Minimierung solcher Verzerrungen stellt daher ein wichtiges Forschungsfeld dar.

Aktuelle Entwicklungen im Bereich der Large Language Models zielen unter anderem auf eine effizientere Modellarchitektur, eine bessere Kontextverarbeitung sowie eine stärkere Integration in multimodale Systeme ab. Letztere kombinieren verschiedene Datentypen wie Text, Sprache und Bilder, um umfassendere und flexiblere Anwendungen zu ermöglichen. Darüber hinaus wird an Methoden gearbeitet, die eine stärkere Kontrolle über die generierten Inhalte erlauben und die Zuverlässigkeit der Modelle erhöhen.

Zusammenfassend lässt sich festhalten, dass Large Language Models eine Schlüsselrolle in der modernen Sprachverarbeitung einnehmen. Sie ermöglichen eine qualitativ hoch-

wertige Analyse und Generierung natürlicher Sprache und tragen wesentlich dazu bei, die Interaktion zwischen Mensch und Maschine natürlicher und effizienter zu gestalten. Trotz bestehender Herausforderungen ist davon auszugehen, dass ihre Bedeutung durch kontinuierliche Fortschritte in Forschung und Entwicklung weiter zunehmen wird.

2.5 Text-To-Speech

Die Sprachsynthese, auch als TTS bezeichnet, bildet eine zentrale Komponente moderner Sprachassistentensysteme und stellt das Gegenstück zur automatischen Spracherkennung dar. Während STT-Verfahren gesprochene Sprache in Text umwandeln, verfolgt die Sprachsynthese das Ziel, geschriebenen Text in natürlich klingende gesprochene Sprache zu transformieren. Dadurch wird es möglich, maschinell generierte Inhalte für den Nutzer hörbar und intuitiv erfahrbar zu machen. Systeme wie Siri, Alexa oder Google Assistant nutzen leistungsfähige TTS-Verfahren, um Antworten akustisch auszugeben und eine dialogbasierte Interaktion zu ermöglichen.

Die grundlegende Herausforderung der Sprachsynthese besteht darin, aus einer abstrakten, symbolischen Repräsentation von Sprache – dem Text – ein kontinuierliches Audiosignal zu erzeugen, das für den Menschen natürlich, verständlich und angenehm klingt. Dabei müssen nicht nur die korrekte Aussprache einzelner Wörter, sondern auch prosodische Merkmale wie Betonung, Intonation, Rhythmus und Sprechgeschwindigkeit berücksichtigt werden. Diese Faktoren sind entscheidend für die Natürlichkeit und Verständlichkeit der generierten Sprache.

Der Prozess der TTS-Synthese lässt sich in mehrere aufeinanderfolgende Verarbeitungsschritte unterteilen. Zunächst erfolgt eine linguistische Analyse des Eingabetextes. In diesem Schritt wird der Text normalisiert, indem beispielsweise Abkürzungen aufgelöst, Zahlen in ausgeschriebene Formen überführt und Satzstrukturen analysiert werden. Anschließend wird der Text in eine phonetische Repräsentation umgewandelt, wobei jedem Wort eine Folge von Lauten (Phonemen) zugeordnet wird.

Darauf aufbauend erfolgt die prosodische Modellierung, bei der festgelegt wird, wie der Text gesprochen werden soll. Hierbei werden Informationen über Satzstruktur, Wortarten und semantische Zusammenhänge genutzt, um geeignete Betonungen, Pausen und Intonationsverläufe zu bestimmen. Diese Phase ist entscheidend für die Natürlichkeit der Sprachsynthese, da monotone oder unpassend betonte Sprache vom Nutzer als unnatürlich wahrgenommen wird.

Im anschließenden Syntheseschritt wird schließlich das eigentliche Audiosignal erzeugt. Historisch wurden hierfür verschiedene Verfahren entwickelt. Frühere Systeme basierten häufig auf regelbasierter Synthese oder konkatenativer Synthese, bei der voraufgenom-

mene Sprachsegmente miteinander kombiniert wurden. Diese Ansätze konnten zwar verständliche Sprache erzeugen, waren jedoch in ihrer Flexibilität eingeschränkt und klangen oft unnatürlich.

Moderne TTS-Systeme nutzen überwiegend Verfahren des maschinellen Lernens, insbesondere neuronale Netze. Ein bedeutender Fortschritt wurde durch neuronale Sprachsynthesemodelle erzielt, die in der Lage sind, Sprache direkt aus Textdaten zu generieren. Beispiele hierfür sind Modelle wie WaveNet oder Tacotron, die eine deutlich natürlichere und flüssigere Sprachwiedergabe ermöglichen. Diese Modelle lernen aus großen Mengen an Sprachdaten die komplexen Zusammenhänge zwischen Text und akustischen Signalen und können dadurch realitätsnahe Sprachmuster erzeugen.

Ein zentrales Qualitätskriterium von TTS-Systemen ist die wahrgenommene Natürlichkeit der generierten Sprache. Diese wird häufig durch subjektive Bewertungsverfahren wie den Mean Opinion Score (MOS) gemessen, bei dem menschliche Testpersonen die Qualität der Sprachwiedergabe bewerten. Neben der Natürlichkeit spielt auch die Verständlichkeit eine wichtige Rolle, insbesondere in Anwendungen, in denen präzise Informationsübermittlung erforderlich ist.

Trotz erheblicher Fortschritte bestehen weiterhin Herausforderungen im Bereich der Sprachsynthese. Dazu zählt insbesondere die realistische Abbildung emotionaler Ausdrucksformen, wie beispielsweise Freude, Trauer oder Ironie. Auch die Anpassung der Stimme an unterschiedliche Kontexte oder Nutzerpräferenzen stellt eine komplexe Aufgabe dar. Darüber hinaus kann die Synthese von mehrsprachigen Inhalten oder von Texten mit Fachterminologie zusätzliche Schwierigkeiten verursachen.

Ein weiterer wichtiger Aspekt ist die Personalisierung von Stimmen. Moderne Systeme ermöglichen es zunehmend, individuelle Stimmen zu erzeugen oder bestehende Stimmen anzupassen. Dies kann beispielsweise dazu genutzt werden, Markenidentitäten zu stärken oder barrierefreie Anwendungen für Menschen mit Sehbehinderungen zu verbessern. Gleichzeitig wirft diese Entwicklung jedoch auch ethische Fragen auf, insbesondere im Hinblick auf den möglichen Missbrauch synthetischer Stimmen.

Im Kontext von Sprachassistenzsystemen trägt die TTS-Technologie maßgeblich zur Nutzererfahrung bei. Eine natürliche und angenehm klingende Sprachwiedergabe kann die Akzeptanz und Benutzerfreundlichkeit eines Systems erheblich steigern, während unnatürliche oder fehlerhafte Synthese zu Frustration führen kann. Daher ist die kontinuierliche Verbesserung der Sprachsynthese ein zentrales Ziel in der Weiterentwicklung solcher Systeme.

Zusammenfassend lässt sich festhalten, dass TTS-Systeme eine essenzielle Rolle in der Mensch-Maschine-Interaktion spielen. Sie ermöglichen es, maschinell generierte Inhalte in eine für den Menschen intuitive Form zu überführen und tragen damit wesentlich zur

Realisierung natürlicher Dialogsysteme bei. Durch Fortschritte im Bereich der künstlichen Intelligenz und neuronaler Netze ist in Zukunft mit weiteren Verbesserungen hinsichtlich Natürlichkeit, Ausdrucksstärke und Anpassungsfähigkeit zu rechnen, wodurch die Bedeutung dieser Technologie weiter steigen wird.

2.6 Aktueller Stand der Technologie?

Kapitel 3

Methodik

Die vorliegende Arbeit orientiert sich am Ansatz des Design-Science-Research (DSR). Dieser ist insbesondere in der Informatik und Wirtschaftsinformatik etabliert und fokussiert die Entwicklung sowie Evaluation innovativer IT-Artefakte zur Lösung konkreter Problemstellungen [1, 2]. Solche Artefakte können unterschiedliche Ausprägungen annehmen und beispielsweise als Konstrukte, Modelle oder Methoden realisiert werden [1, 2].

Die Wahl dieses Forschungsansatzes ergibt sich aus der Zielsetzung der Arbeit, einen datenschutzfreundlichen Sprachassistenten zu konzipieren und prototypisch umzusetzen. Im Kontext aktueller, überwiegend cloudbasierter Systeme besteht die zentrale Problemstellung in der umfangreichen Verarbeitung und Speicherung sensibler Nutzerdaten auf externen Servern. Daraus ergibt sich die Notwendigkeit, alternative Lösungsansätze zu entwickeln, die eine stärkere Wahrung der Privatsphäre ermöglichen. DSR bietet hierfür einen geeigneten methodischen Rahmen, da er explizit auf die Entwicklung und Evaluation technischer Artefakte zur Lösung realer Probleme ausgerichtet ist [1, 2].

Beleg!

3.1 Forschungsansatz: Design Science Research Methodology

Für die systematische Durchführung der Forschung wird die Design-Science-Research-Methodology (DSRM) nach Pfeffers et al. [1] angewandt. Diese Methodik stellt ein prozessorientiertes Rahmenmodell bereit, das aus sechs zentralen Aktivitäten besteht und auf den wissenschaftlichen Gütekriterien für DSR nach Hevner et al. aufbaut [1, 2].

Ausgangspunkt der DSRM ist die Identifikation eines relevanten Problems sowie die Darlegung der zugrunde liegenden Motivation [1]. Im Rahmen dieser Arbeit besteht die Problemstellung in der mangelnden Datenschutzkonformität gängiger, cloudbasierter Sprachassistenten, bei denen Sprachdaten regelmäßig an externe Server übertragen und dort verarbeitet werden. Die Motivation ergibt sich aus dem zunehmenden gesellschaftlichen und regulatorischen Interesse an Datenschutz sowie dem Bedarf nach alternativen, lokal arbeitenden Systemen, die eine stärkere Kontrolle über personenbezogene Daten ermöglichen.

Beleg!

Beleg wie im Überkapitel!

Auf Basis der identifizierten Problemstellung werden im zweiten Schritt konkrete Zielsetzungen für das zu entwickelnde Artefakt formuliert [1]. Im Mittelpunkt stehen dabei insbesondere die vollständige Offline-Fähigkeit des Systems, die Minimierung der Datenverarbeitung außerhalb des lokalen Geräts sowie eine hinreichende funktionale Leistungsfähigkeit, um eine praktikable Alternative zu bestehenden Lösungen darzustellen. Ergänzend werden Anforderungen an Benutzerfreundlichkeit und Systemreaktionszeit berücksichtigt.

Daraufhin erfolgt die Konzeption und prototypische Umsetzung des Artefakts [1]. Ziel ist die Entwicklung eines Offline-Sprachassistenten, der zentrale Funktionen wie Wakeword-Erkennung, Sprachverarbeitung sowie Antwortgenerierung lokal ausführt. Die konkrete architektonische Ausgestaltung sowie die Implementierung werden in den nachfolgenden Kapiteln detailliert beschrieben.

Als vierter Schritt wird durch die Demonstration die Anwendbarkeit des entwickelten Artefakts im Nutzungskontext aufgezeigt [1]. Hierzu wird der Prototyp in typischen Anwendungsszenarien eingesetzt, in denen Nutzer über Sprachbefehle mit dem System interagieren. Ziel ist es, die grundsätzliche Funktionsfähigkeit sowie die praktische Einsetzbarkeit des Ansatzes zu veranschaulichen [2].

Nah an die Demonstration angeknüpft wird das Artefakt dann gegen die Ursprungsproblematik evaluiert [1]. Im Zuge dessen werden die gemessenen Ergebnisse mit den anfänglichen Zielen, aber auch ähnlichen Lösungen verglichen [1]. Im Falle des Sprachassistenten können beispielsweise die Antwortzeiten verschiedener Hardware gegen existierenden Cloud-Lösungen verglichen werden. Weiterhin werden im Evaluationsteil auch verschiedenste Use Cases für das Produkt vorgestellt und die Funktion des Sprachassistenten in diesen erläutert.

Abschließend werden im sechsten und letzten Schritt die Ergebnisse der Arbeit sowie die Bedeutung des entwickelten Artefakts für die Forschung und Praxis kommuniziert [1]. Dies beinhaltet unter anderem eine kritische Diskussion über die Limitationen, wie die begrenzte Rechenleistung bestimmter Hardware, sowohl auch der Herausforderungen, wie Modellaktualisierungen [2].

3.2 Evaluationskonzept

Die Evaluation dient der systematischen Bewertung des entwickelten Offline-Sprachassistenten hinsichtlich der zuvor definierten Zielsetzungen [1]. Im Fokus steht insbesondere die Untersuchung, inwieweit das Artefakt eine datenschutzfreundliche Alternative zu cloudbasierten Sprachassistenten darstellen kann und gleichzeitig eine ausreichende funktionale Leistungsfähigkeit bietet.

Orientiert wird sich an den im Rahmen der DSRM formulierten Anforderungen, wobei die Evaluation sowohl technische als auch qualitative Bewertungskriterien umfasst. Hierzu werden verschiedene Nutzungsszenarien definiert, in denen der Sprachassistent unter realitätsnahen Bedingungen getestet wird.

Ein zentrales Evaluationskriterium stellt die technische Leistungsfähigkeit des Systems dar. Hierbei werden insbesondere die Antwortzeiten des Sprachassistenten, die Stabilität der Verarbeitungskette sowie die Ressourcenanforderungen auf unterschiedlicher Hardware untersucht. Die Messung der Antwortzeiten erfolgt anhand definierter Sprachbefehle, wobei die Zeitspanne zwischen Spracheingabe und Systemantwort erfasst wird.

Ergänzend wird die funktionale Qualität des Systems bewertet. Hierzu wird untersucht, ob zentrale Funktionen wie Wakeword-Erkennung, Sprachtranskription und Antwortgenerierung zuverlässig ausgeführt werden. Die Bewertung erfolgt anhand derselben exemplarischen Sprachbefehle aus der vorangehenden Evaluation.

Zur Einordnung der Ergebnisse wird letztlich ein Vergleich mit bestehenden cloudbasierten Sprachassistenten und DIY-Architekturen durchgeführt. Dabei werden insbesondere Unterschiede hinsichtlich Datenschutz, Reaktionszeit und funktionalem Umfang betrachtet. Ziel des Vergleichs ist nicht die vollständige Gleichwertigkeit mit kommerziellen Systemen, sondern die Bewertung, inwieweit ein lokal arbeitender Sprachassistent eine praktikable Alternative darstellen kann.

Abschließend werden die Ergebnisse im darauf folgenden Kapitel kritisch reflektiert und hinsichtlich bestehender Limitationen diskutiert. Dazu zählen insbesondere hardwarebedingte Leistungsgrenzen, mögliche Einschränkungen bei der Spracherkennung und Sprachsynthese sowie Herausforderungen bei der Aktualisierung lokal betriebener Modelle.

Kapitel 4

Prototypische Implementierung

Ziel dieses Kapitels ist die prototypische Umsetzung eines offline-fähigen Sprachassistenten als Lösung für die in Kapitel 1 beschriebene Problemstellung. Zunächst werden hierfür funktionale- und nicht-funktionale Anforderungen definiert, um dem Prototypen einen klaren Rahmen zu geben. Anschliessend

4.1 Anforderungsanalyse

Im Kern der Entwicklung des Prototyps

4.2 Auswahl der Entwicklungsplattform und Komponenten

Test2

4.3 Umsetzung

Test3

4.4 Demonstration

Test4

Kapitel 5

Evaluation

5.1 Versuche auf verschiedener Hardware

5.1.1 Raspberry Pi

5.1.2 Macbook Air M4

5.1.3 Beelink GT9 Pro

5.2 Vergleich mit Cloud-basierten Lösungen und DIY-Architekturen

5.2.1 Alexa

5.2.2 Siri

5.2.3 Homeassistant Voice Assistant

5.3 Use-Cases

5.3.1 Smart-Home Steuerung

5.3.2 Pflege

5.3.3 Hausaufgaben Helfer

Kapitel 6

Fazit und Ausblick

6.1 Ergebnisinterpretation

Test1

6.2 Beitrag der Arbeit

Test2

6.3 Limitationen der Studie

Test3

6.4 Forschungsausblick

Test4

Literatur

- [1] Ken Peffers, Tuure Tuunanen, Marcus Rothenberger und S. Chatterjee. „A Design Science Research Methodology for Information Systems Research“. In: *Journal of Management Information Systems* 24 (1. Jan. 2007), S. 45–77. doi: [10.2753/MIS0742-1222240302](https://doi.org/10.2753/MIS0742-1222240302).
- [2] Alan Hevner, Alan R, Salvatore March, Salvatore T, Park, Jinsoo Park, Ram und Sudha. „Design Science in Information Systems Research“. In: *Management Information Systems Quarterly* 28 (1. März 2004), S. 75.

Anhang A

Anhang A

Anhang B

Anhang B